

Accelerating LLM Inference:

KV Cache Mechanisms and VRAM Compression Strategies

B812111001 張博翔 . 2026 06 07

LLM 進行長對話時，每生成新字都須重新計算先前對話的 Key-Value，導致延遲隨對話長度呈二次方成長而面臨運算瓶頸。KV Cache 技術透過將已計算的 Key-Value 矩陣暫存於記憶體中，使模型無須重複運算並降低推論延遲。

然而在長文本或多用戶並行的場景下，其佔用的 VRAM 可能高達數十 GB，導致 CUDA OutOfMemoryError。為解決此問題因而提出多種 VRAM 壓縮技術，包括 4-bit 量化（Quantization）、分頁式 KV 管理（PagedAttention）、以及 Sparse Attention，將龐大的快取空間壓縮至數 GB 以內並維持可接受的精度損失。

本專題旨在探討 KV Cache 的運作機制及在 AI 中的角色，並分析 VRAM 壓縮技術的時空與精度 Trade-off。KV Cache 直接對應 Dynamic Programming 最優子結構思維，將子問題的計算結果儲存以避免重複求解，是本專題與演算法課程最主要的概念連結。