

Experiment 3 Report

BCI 初應用與資料蒐集

劉漾晴 張博翔

1 Introduction

腦機介面 (Brain-Computer Interface, BCI) 是一種實現大腦與外部設備直接通訊的技術，其中腦電圖 (Electroencephalography, EEG) 因其非侵入性與高時間解析度，成為最廣泛使用的訊號來源。傳統的 EEG 分類方法依賴手工特徵設計，過程耗時且容易遺漏關鍵資訊。近年來，深度卷積神經網路已成功應用於 EEG 的端到端解碼，Zied et al. [1] 提出的頻譜圖-based CNN 架構 (pCNN) 能自動從時頻表徵中學習判別性特徵，免除手工特徵工程。

本實驗旨在使用 BrainLink 單通道乾式電極裝置所收集的 EEG 訊號，對三種心理狀態進行分類：Relax (放鬆)、Concentration (專注) 及 Blink (眨眼)。BrainLink 為消費級裝置，訊號品質較不穩定，因此如何在有限且帶有雜訊的資料上建立穩健的分類模型為本實驗之核心挑戰。我們採用 STFT 頻譜圖轉換搭配 pCNN 架構，並以控制變因法比較無增強與含資料增強兩種條件下的模型表現。最終模型在 5-Fold Cross Validation 中達到 82.0% 的準確率。

2 Methodology for Model Optimization

本節詳細說明自錄資料集、資料處理流程、模型超參數調整，以及用於評估三分類模型效能的方法。

2.1 資料集與環境

- 資料來源：bci_dataset_114-2，由三位組員自錄之腦波資料。
- 訊號類型：單通道 (Fp1) EEG 時域訊號，透過 BrainLink 乾式電極頭戴裝置進行記錄。
- 取樣頻率：512 Hz。
- 標籤類別：Relax (放鬆, Label 0)、Concentration (專注, Label 1)、Blink (眨眼, Label 2)。
- 總樣本數：254 筆。
- 實驗環境：Python 3.11，搭配 TensorFlow/Keras、Scikit-learn、NumPy 及 SciPy 等套件。

2.2 資料前處理與分類方法

2.2.1 前處理流程

1. **Zero-Padding**：由於 BrainLink 裝置在實際記錄過程中可能因藍牙連線不穩定而導致部分資料遺失，每個檔案預期應有 10240 筆資料（20 秒 $\times$ 512 Hz）。為確保輸入維度一致性，我們對每個檔案的資料長度進行檢查：若資料量少於 10000 筆則捨棄該檔案；若資料量介於 10000 至 10240 筆之間，則在訊號末端補零（Zero-padding）至 10240 筆，使其達到標準長度。
2. **不使用極端值剔除 (Extreme Value Rejection)**：初步實驗曾嘗試設定 1000 μ V 的閾值來剔除極端值，但此舉會過度濾除 Blink（眨眼）狀態的訊號。這導致 Blink 類別的樣本數嚴重不足，即使後續使用類別權重（class weight）進行補償，模型準確率仍停留在 50-60% 左右。因此，最終選擇不進行極端值剔除，以保留完整的眨眼特徵。
3. **低通濾波 (Lowpass Filter < 40 Hz)**：僅保留 0-40 Hz 的頻帶，去除高頻雜訊與肌電干擾，同時保留與認知狀態相關的 Delta、Theta、Alpha 及 Beta 波等主要頻帶。
4. **Min-Max Normalization**：每張頻譜圖獨立進行 Min-Max 正規化，將數值範圍縮放至 $[0, 1]$ 。

為了消除受試者間的個體差異與儀器阻抗造成的振幅變動，我們在 S2I 模組中加入逐樣本 (Sample-wise) 的 Min-Max Normalization，將頻譜圖中的每個像素值 x 縮放至 $[0, 1]$ 區間：

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

此舉確保了輸入模型的所有特徵具備相同的量綱，有助於加速卷積神經網路的收斂並提升泛化能力。

2.2.2 資料切割與時頻分析

為了將連續的 EEG 訊號轉換為可供模型學習的時頻表徵，我們參考 Bizopoulos et al. [2] 所提出的 Signal2Image (S2I) 概念，使用短時傅立葉變換（Short-Time Fourier Transform, STFT）將原始 EEG 訊號轉換為二維頻譜圖。各參數設定如下：

- **取樣頻率 (fs)**：512 Hz，與 BrainLink 裝置的實際取樣率一致。
- **Window 長度**：1 秒（512 點）。
- **Overlap (重疊)**：0.5 秒（256 點），步長為 0.5 秒。
- **NFFT**：512 點，頻率解析度為 1 Hz ($fs/nfft = 512/512$)。
- **頻率範圍**：0-40 Hz，共 41 個頻率 bins。
- **時間幀數**：每段 20 秒的 trial 產生 39 個時間幀 (frames)。
- **邊界處理**：boundary=None，不在訊號兩端補零。

對於長度 $L = 10240$ 點的訊號，其產生的時間幀數 T 計算如下：

$$T = \frac{L - N_{\text{overlap}}}{N_{\text{win}} - N_{\text{overlap}}} = \frac{10240 - 256}{512 - 256} = \frac{9984}{256} = 39 \quad (2)$$

因此，最終輸出的特徵尺寸為 $41(\text{Frequency Bins}) \times 39(\text{Time Frames})$ 。

每筆原始 EEG 訊號（10240 點）經 STFT 轉換後，輸出頻譜圖尺寸為 $254 \times 41 \times 39 \times 1$ ，其中 254 為資料數，41 為頻率 bins（0-40 Hz，1 Hz/bin），39 為時間幀數，1 為單通道 Fp1。

2.2.3 分類方法

本實驗採用基於頻譜圖的卷積神經網路（Spectrogram-based Convolutional Neural Network, pCNN）進行端到端（end-to-end）學習。原始 EEG 訊號經 STFT 轉換為二維頻譜圖後，直接輸入深度學習模型進行分類。此方法的優勢在於模型能自動從時頻表徵中學習判別性特徵，避免了人為特徵設計的偏差與資訊損失。

2.2.4 資料增強 (Data Augmentation)

為了解決訓練資料不足的問題（每 fold 僅約 182 筆），我們在訓練階段採用了混合資料增強策略，包含：

- 高斯雜訊（Gaussian noise, $\sigma = 0.02$ ）：模擬 EEG 訊號的微幅波動
- 時間軸平移（Time shift, ± 5 frames）：模擬反應時間的微小差異
- 頻率遮罩（Frequency masking, 1-5 bins）：模擬特定頻帶的雜訊干擾
- 時間遮罩（Time masking, 1-3 frames）：模擬暫時性的訊號丟失

上述增強僅應用於訓練集，每 fold 的訓練樣本數從約 182 筆擴增至 350 筆，有效降低了模型過擬合的風險。為驗證資料增強的實際效益，我們先以含增強之設定訓練至收斂並獲得最佳模型後，再以相同超參數但不使用任何資料增強的方式重新訓練。

2.3 模型架構與超參數設定

本實驗採用基於 Zied et al. [1] 所提出之 pCNN 架構，並針對單通道小樣本 EEG 的特性進行調整。模型總參數量為 157,515 個，詳細架構如表 1 所示。

模型訓練所使用的超參數設定整理於表 2。

Table 1: pCNN 模型架構

層 (Layer)	輸出形狀 (Output Shape)	參數量 (Param #)
Input	(None, 41, 39, 1)	0
Conv2D (24, 12×12)	(None, 41, 39, 24)	3,480
BatchNorm + MaxPool + Dropout(0.3) + ReLU	(None, 20, 19, 24)	96
Conv2D (48, 8×8)	(None, 20, 19, 48)	73,776
BatchNorm + MaxPool + Dropout(0.4) + ReLU	(None, 10, 9, 48)	192
Conv2D (96, 4×4)	(None, 10, 9, 96)	73,824
BatchNorm + MaxPool + Dropout(0.5) + ReLU	(None, 5, 4, 96)	384
Flatten	(None, 1920)	0
Dense (3, softmax)	(None, 3)	5,763
Total		157,515

Table 2: 模型超參數設定

參數 (Parameter)	設定值	說明
Optimizer	Adam (lr=0.001)	自適應學習率優化器
Loss	Sparse Categorical Crossentropy	多分類交叉熵損失
Batch Size	8	小批量以輔助正則化
Max Epochs	100	配合 EarlyStopping 使用
EarlyStopping	patience=20	監控驗證損失，防止過擬合
ReduceLROnPlateau	factor=0.5, patience=8	學習率停滯時自動減半
L2 Regularization	0.001	限制權重的大小
Class Weight	balanced	平衡各類別的損失貢獻

2.4 後處理

本實驗未使用任何後處理方法。

2.5 效能評估方法

實驗採用 **5-Fold Stratified Cross-Validation** 作為主要的模型驗證方法。評估指標選用 **Accuracy (準確率)** 與 **Macro F1-Score**。保留 10% 的資料作為獨立的測試集 (**Test Set**)，以 CV 中表現最佳的模型進行最終評估。此外，我們亦嘗試將 5 個 Fold 的最佳模型進行集成 (**Ensemble**)，採用 Soft Voting 策略，對各模型的輸出機率取平均後再 **argmax**，希望進一步提升測試集表現。

3 Results and Analysis of Model Optimization

為系統性評估各項技術的貢獻，本實驗分別訓練了「無資料增強」與「含資料增強」兩個版本的模型。其中含增強版本將訓練集擴增至 250 筆（約為原始的 1.38 倍），此設定參考常見的保守增強比例，在增加樣本多樣性與避免過度扭曲原始資料分布之間取得平衡。

3.1 無資料增強 Baseline 結果

作為對照基準，我們首先在不使用任何資料增強的情況下進行訓練。5-Fold CV 及測試集結果如下：

Fold 1: Acc = 0.9130, F1 = 0.9122

Fold 2: Acc = 0.5000, F1 = 0.4413

Fold 3: Acc = 0.8261, F1 = 0.8255

Fold 4: Acc = 0.5556, F1 = 0.5019

Fold 5: Acc = 0.7556, F1 = 0.7546

Overall Mean Accuracy: 0.7100 $\pm$ 0.1579

Overall Mean F1-Score: 0.6871 $\pm$ 0.1839




Figure 1: 無資料增強模型之 5-Fold CV 摘要圖

測試集結果（無增強）：

- Test Loss: 0.5099
- Test Accuracy: 0.8462
- Test F1-Score (Macro): 0.8472




Figure 2: 無資料增強模型於測試集之混淆矩陣

無增強 Baseline 分析：

- 平均 CV Accuracy 為 71.0%，標準差高達 15.8%，顯示模型在不同資料分割下極不穩定
- 各 Fold 之間差異懸殊：Fold 2 僅 50.0%，Fold 1 卻高達 91.3%
- 測試集中，Concentration（專注）有 2/9 被誤判為 Relax，Blink 有 2/9 被誤判為 Focus
- 雖然測試集表現尚可（84.6%），但 CV 標準差過大反映出典型的過擬合現象：訓練資料不足（每 fold 僅 182 筆）導致 157,515 參數的深度模型無法穩定學習

3.2 含資料增強之最佳化結果

加入混合資料增強（擴增至 250 筆）後，模型的表現獲得顯著提升：

Fold 1: Acc = 0.8696, F1 = 0.8642

Fold 2: Acc = 0.8261, F1 = 0.8190

Fold 3: Acc = 0.8478, F1 = 0.8443

Fold 4: Acc = 0.7556, F1 = 0.7565

Fold 5: Acc = 0.8000, F1 = 0.7919

Overall Mean Accuracy: 0.8198 +/- 0.0395

Overall Mean F1-Score: 0.8151 +/- 0.0381




Figure 3: 含資料增強模型之 5-Fold CV 摘要圖

測試集結果 (含增強)：

- Test Loss: 0.4416
- Test Accuracy: 0.9231
- Test F1-Score (Macro): 0.9213




Figure 4: 含資料增強模型於測試集之混淆矩陣

3.3 Ensemble 集成結果

在取得 5 個 Fold 的最佳模型後，我們以 Soft Voting 方式整合 5 個 Fold 最佳模型，分別對無增強與含增強兩個版本進行集成預測。

3.3.1 無增強 Ensemble




Figure 5: 無增強 Ensemble 模型於測試集之混淆矩陣

無增強版本的 Ensemble 測試準確率為 80.8%，Macro F1-Score 為 0.81。相較於無增強單一最佳模型的 84.6%，Ensemble 反而下降了 3.8 個百分點。

3.3.2 含增強 Ensemble




Figure 6: 含增強 Ensemble 模型於測試集之混淆矩陣

含增強版本的 Ensemble 測試準確率為 88.5%，Macro F1-Score 為 0.88。相較於含增強單一最佳模型的 92.3%，Ensemble 同樣下降了 3.8 個百分點。

表 3 整理了兩個版本單模與 Ensemble 的完整對照。

Table 3: 單模（最佳 Fold）與 Ensemble 測試集比較

2* 方法	無增強		含增強	
	Test Acc	Test F1	Test Acc	Test F1
Single Best Model	0.8462	0.8472	0.9231	0.9213
Ensemble (Soft Voting)	0.8077	0.8077	0.8846	0.8807

Ensemble 未見效果之分析 無論是無增強或含增強版本，Ensemble 的測試集表現均低於單一最佳模型。此結果可從以下角度加以解釋：

1. **測試集樣本量過小，統計估計不穩定**：本實驗測試集僅含 26 筆樣本，單一樣本的誤判即可造成約 3.8% 的波動。在如此小的樣本規模下，Ensemble 平均機率所帶來的效益極為有限。
2. **各 Fold 模型間多樣性不足**：5-Fold 切分後各折訓練集重疊比例高達 75%，導致各 Fold 模型學到高度相似的決策邊界。當各模型犯相同方向的錯誤時，Soft Voting 平均機率不僅無法修正偏差，反而可能強化錯誤。
3. **Focused 類別存在系統性混淆**：含增強 Ensemble 中，Focused 被誤判為 Closed eyes 的樣本由單模的 1/9（11.1%）上升至 3/9（33.3%），是集成表現下滑的主要來源。無增強版本也觀察到類似現象。

3.4 資料增強效果對照分析

表 4 整理了無增強、含增強單模，以及含增強 Ensemble 三個版本的完整效能對照。

Table 4: 資料增強與 Ensemble 效果對照

指標	無增強 (Baseline)	含增強 Single Best	含增強 Ensemble
CV Mean Accuracy	0.7100 ± 0.1579	0.8198 ± 0.0395	—
CV Mean F1-Score	0.6871 ± 0.1839	0.8151 ± 0.0381	—
Test Accuracy	0.8462	0.9231	0.8846
Test F1-Score	0.8472	0.9213	0.8807
Relax Recall	8/8 (100%)	8/8 (100%)	8/8 (100%)
Focus Recall	7/9 (77.8%)	8/9 (88.9%)	6/9 (66.7%)
Blink Recall	7/9 (77.8%)	9/9 (100%)	9/9 (100%)

增強效果分析

- **CV 平均準確率提升 11.0 個百分點** ($71.0\% \rightarrow 82.0\%$)，效果顯著
- **標準差大幅降低** ($15.8\% \rightarrow 4.0\%$)：無增強時各 Fold 差異懸殊 ($50.0\%-91.3\%$)，增強後模型穩定性獲得顯著改善
- **Focus 類別 Recall 提升 11.1%** ($77.8\% \rightarrow 88.9\%$)，Blink 類別 Recall 從 77.8% 提升至 100%
- **測試集準確率從 84.6% 提升至 92.3%** ，增加 7.7 個百分點
- 測試集 Loss 從 0.51 降至 0.44，驗證增強有效抑制了過擬合

Ensemble 與單模之比較 含增強的 Ensemble (88.5%) 雖優於無增強 Baseline (84.6%)，但仍低於含增強單模最佳結果 (92.3%)。此差距主要源自 Focus 類別：Ensemble 的 Focus Recall 為 66.7% ，較單模的 88.9% 下滑 22.2 個百分點。整體而言，**資料增強是本實驗最關鍵的改善手段**；Ensemble 在現有樣本規模下未能帶來額外增益。

3.5 各類別表現深入分析

根據含增強單一最佳模型的最終混淆矩陣：

- **Blink (眨眼)**：辨識率達 100% (9/9)，為三類中表現最佳。這歸因於眨眼在時域上會產生明顯的瞬態波形，在頻譜圖上表現為獨特的寬頻垂直條紋，對 CNN 而言是極易學習的特徵。
- **Relax (閉眼/放鬆)**：辨識率同樣達 100% (8/8)。閉眼放鬆狀態下，大腦枕葉會產生明顯的 Alpha 波 (8–13 Hz) 增強現象，此頻域特徵在 Fp1 電極位置仍可被穩定捕捉。
- **Concentration (專注)**：辨識率為 88.9% (8/9)，為三類中最低，僅有 1 筆被誤判為 Relax。相較於無增強版本的 77.8%，增強後提升了 11.1 個百分點。此結果反映了單通道 Fp1 系統的固有局限：前額葉在專注與放鬆時的 EEG 模式本質上較為相似。

3.6 關鍵改善因素總結

回顧整個實驗歷程，以下調整對模型效能的提升貢獻最為顯著：

1. **資料增強 (+11.0% CV Accuracy)**：這是本實驗中貢獻最大的單一技術。混合增強策略將訓練集擴增至 250 筆，不僅提升了準確率，更使標準差從 15.8% 降至 4.0%，大幅改善了模型穩定性。
2. **移除 Extreme Value Rejection**：初步實驗中加入極端值剔除後，Blink 類別幾乎無法被辨識（整體準確率僅 50–60%）。移除此步驟後，模型得以保留完整的眨眼波形特徵。
3. **pCNN 架構設計**：採用 Zied et al. [1] 的 pCNN 架構，透過卷積層的逐步降維 (24 → 48 → 96 filters) 搭配 L2 Regularization 與 Dropout，在不需要手工特徵的情況下自動學習時頻表徵，與傳統需要手動設計特徵的方法相比具有更好的自適應性 [2]。

4 Discussion

本實驗的核心挑戰在於使用極少量的自錄資料（254 筆）訓練一個參數量達 157,515 的深度學習模型。從無增強 Baseline 的結果（CV 71.0% $\pm$ 15.8%）可以清楚看到，直接使用原始資料訓練會導致嚴重的過擬合與不穩定，各 Fold 之間的準確率差異高達 41.3 個百分點（50.0%-91.3%）。混合資料增強技術透過對現有樣本施加可控的變形（雜訊、平移、遮罩），將訓練集從約 182 筆擴增至 250 筆（約為原始的 1.38 倍），成功將 CV 平均準確率提升至 82.0%，標準差降至 4.0%，測試集準確率更達到 92.3%。

然而，本研究仍存在若干限制。首先，BrainLink 頭戴裝置的乾式電極對皮膚接觸狀態、周圍電磁環境及受試者微小動作相當敏感，容易引入難以控制的雜訊。其次，使用單通道（Fp1）進行三種認知狀態的判別在本質上受到空間資訊不足的限制，這在 Concentration 與 Relax 類別的混淆上得到了體現：即使在含增強的最佳模型中，Concentration 仍有 1/9 的樣本被誤判為 Relax。

在 Ensemble 集成方面，本研究以 Soft Voting 對 5 個 Fold 最佳模型進行集成。無增強版本的 Ensemble 測試準確率為 80.8%（低於單模的 84.6%），含增強版本的 Ensemble 為 88.5%（低於單模的 92.3%）。兩個版本的 Ensemble 均未能超越單一最佳模型，主要原因有三：(1) 5-Fold 切分後各子模型訓練集重疊率高達 75%，導致模型間多樣性不足；(2) 各子模型在 Focused / Closed eyes 邊界學到高度相似的錯誤傾向，Soft Voting 平均後偏差反而更為明顯；(3) 測試集僅 26 筆，集成方差縮減的優勢難以在此規模下統計顯著地體現。

值得注意的是，無增強版本的測試集表現（84.6%）與 CV 平均（71.0%）之間存在 13.6 個百分點的差距，這暗示測試集的 26 筆樣本可能恰好是較容易分類的樣本，進一步說明了小樣本評估的不穩定性。相比之下，含增強版本的 CV 平均（82.0%）與測試集（92.3%）之間的差距縮小至約 10 個百分點，且標準差大幅降低，顯示增強有效提升了模型的泛化能力。

在未來展望方面，下一個階段的實驗將著重於：(1) 增加受試者數量以提升資料多樣性；(2) 進行 Leave-One-Subject-Out (LOSO) 跨受試者驗證，以更嚴謹的方式評估模型的泛化能力；(3) 探索遷移學習 (Transfer Learning) 或領域適配 (Domain Adaptation) 技術，以提升模型對新使用者的適應性；(4) 將現行固定的 CNN Signal-to-Image (S2I) 轉換模組改為可學習架構，使卷積核權重能接受分類損失的梯度回傳，與後端分類器進行端對端 (end-to-end) 聯合優化。本研究中 Focused 與 Closed eyes 的持續混淆，推測部分根源在於 S2I 轉換後兩類影像的特徵差異本身不足；若轉換模組能針對分類目標自適應調整，有望從特徵表示層根本改善類別可分性，並在樣本擴充後與異質模型集成策略協同發揮效益。

5 Conclusion

本實驗成功利用 BrainLink 單通道 Fp1 EEG 裝置，結合 STFT 頻譜圖轉換與 pCNN 深度學習模型，對 Relax（放鬆）、Concentration（專注）及 Blink（眨眼）三種認知狀態進行分類。透過系統性的控制變因實驗，我們驗證了混合資料增強對於小樣本 EEG 分類的關鍵作用：CV 平均準確率從無增強的 71.0% 提升至含增強的 82.0%（+11.0%），標準差從 15.8% 降至 4.0%，測試集準確率從 84.6% 提升至 92.3%，Macro F1-Score 達 0.92。其中 Blink 和 Relax 狀態達到 100% 的辨識率，Concentration 狀態亦達 88.9%。未來工作將聚焦於增加受試者數量及進行跨受試者泛化能力驗證。

Appendix A Additional Information

You can find the source code on GitHub: [GitHub Repository](#).

Appendix B Experimental Results

Tables or graphs with raw data

References

- [1] Z. Tayeb, J. Fedjaev, N. Ghaboosi, C. Richter, L. Everding, X. Qu, Y. Wu, G. Cheng, and J. Conradt, “Validating deep neural networks for online decoding of motor imagery movements from eeg signals,” *Sensors*, vol. 19, p. 210, Jan. 2019.
- [2] P. Bizopoulos, G. I. Lambrou, and D. Koutsouris, “Signal2image modules in deep neural networks for eeg classification,” *Proceedings of the 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 702–705, 2019.